人工智能评分参与高考网评一评的应用实践

何屹松[1] 孙媛媛[1] 江光贤[2] 张 凯[2]
（1. 安徽省教育招生考试院，合肥 230001；2. 科大讯飞股份有限公司，合肥 230001）

摘要： 对人工智能评分参与高考网评一评的可行性进行探索。在已有“评卷辅助平台”基础上，增加数据交换接口和验标集专家评分功能模块，从管理视角和应用视角2个方面给出较为完整的解决方案。对设计方案在2020年高考数学填空题中进行人工智能评分参与一评的应用性验证，结果显示：填空题总分的“机一评”分数与“人一评”分数的一致率达到99.50%，“机一评”分数与实际全部采用人工双评模式的报道分一致率超过99.90%。人工智能评分的应用性验证说明，在半客观的填空题型中，采用计算机替代“人一评”是可行的，“人机协作”评卷新模式有广阔的应用前景。

关键词： 人工智能评分；网上评卷；人工评卷；高考网评；人机协作评卷模式

【中图分类号】 G405 **【文献标识码】** A **【文章编号】** 1005-8427(2021)09-0040-7

DOI: 10.19360/j.cnki.11-3303/g4.2021.09.006

随着人工智能技术的发展，人工智能辅助网上评卷已经取得实质性进展。在评分效果方面，人工智能评分具有极高的效率和良好的评分准确性[1]，具有多方位的辅助质检功能，可更新迭代成为客观易用的第三方质量评价标准。在应用模式方面，通过接口方式开发中间交互系统——“评卷辅助平台”[2]，使“网上评卷系统”与“智能评分系统”在网络链接、数据交换、实时共享、访问控制等方面实现融合，进而实现操作过程的标准化、实时化应用。在性能提升方面，通过“专家随机抽取+智能挑选样卷+聚类分段补充”的定标集选取策略[3]，提升了评分模型对各分数段的建模能力，使得人工智能评分系统拓展了对专家评分和阅卷教师评分的综合学习能力，从而能够给出每个待评样本准确的评分。

为进一步拓展人工智能在评卷中的应用，本研究尝试对高考数学填空题进行智能评分，并将评分结果作为一评分参与到整个评卷过程中，以期形成“人一评”+“机一评”的评卷模式。

1 人工智能评分参与一评的可行性分析

就管理而言，人工智能评分参与一评过程需要考虑人工智能评分的可信度、能够完成的一评量和技术上如何实现等问题。本研究在进行方

收稿日期： 2021-01-18

作者简介： 何屹松（1965— ），男，安徽省教育招生考试院高级工程师；
孙媛媛（1984— ），女，安徽省教育招生考试院；
江光贤（1988— ），男，科大讯飞股份有限公司软件工程师；
张 凯（1990— ），男，科大讯飞股份有限公司软件工程师。

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

案设计时,因为高考数学填空题的正确答案客观性强、易于评判、单题分值较大,所以被作为智能评分参与一评的首选目标。

人工智能评分时,针对标准答案唯一或可穷举的填空题(如数学填空题、英语填空题、语文名篇名句默写题),在可供参考的标准答案基础上,需要引入验标集,即从全部考生的作答答案中,挑选出涵盖所有答案(包括错误答案)的样本,形成集合。先由学科专家进行人工评分,再由计算机对人工专家评分进行深度学习,建立评分模型,通过反复的验证和学习,最终达到机评与人评完全一致,至此完成对待评样本的智能评分。上述智能评分过程见图1。

本研究在方案设计时,首先选用2018年、2019年普通高考数学(文科、理科)全国Ⅰ卷的填空题(共4小题,每小题5分)进行可行性分析。选取安徽省考生样本,其中2018年文科数学填空题考生作答样本量为17.58万份、理科为24.33万份,2019年文科数学填空题考生作答样本量为18.94万份、理科为23.09万份。

对上述全部样本进行智能评分,选择机评与人评一致率达到或超过99%的样本作为高置信度样本。2018年文科数学填空题高置信度机评样本数量为13.24万份(占比75.31%)、理科为16.05万份(占比65.97%),2019年文科数学填空题高置信度机评样本数量为11.58万份(占比61.14%)、理科数学为12.97万份(占比56.17%)。造成文理科之间、不同年份之间高置信度机评样本百分比不一致的原因,主要是填空题正确答案的表达形式和考生作答内容的差异性造成的。以2018年文科数学和2019年理科数学填空题为例:2018年文科数学4个填空题的标准答案分别为$\frac{2\sqrt{3}}{3}$、$2\sqrt{2}$、6、-7,答案直接明了,评分标准也容易统一;2019年理科数学4个填空题的标准答案分别为$y=3x$、$\frac{121}{3}$、$\frac{9}{50}$、2,包含表达式、分数、数值3种形式,其中,分数书写为上下结构,考生给出的答案形式不一,但其等价转换均可视为正确答案。这2种因素叠加,使计算机在识别转写时存在一定难度,从而造成识别转写精度降低,给智能评分效果带来一定的影响。

将以上高置信度样本的计算机智能评分与人工评分的最终报道分进行一一对应分析,按照同一考生每小题机评分与人评报道分完全相等算作人机一致,2018年文科数学填空题人机一致率为99.89%、理科数学填空题人机一致率为99.91%,2019年文科数学填空题人机一致率为99.61%、理科数学填空题人机一致率为99.42%。按小题进行人机效果比对的数据见表1,其一致率均达到99%以上。需要说明的是,表1中每一小题的一致率均高于整个大题的一致率,这是因为在按小题进行人机一致率效果比对时,不再考虑其他小题是否一致,由于整体一致率与小题一致率非常接近,也就证明填空题的客观性是非常

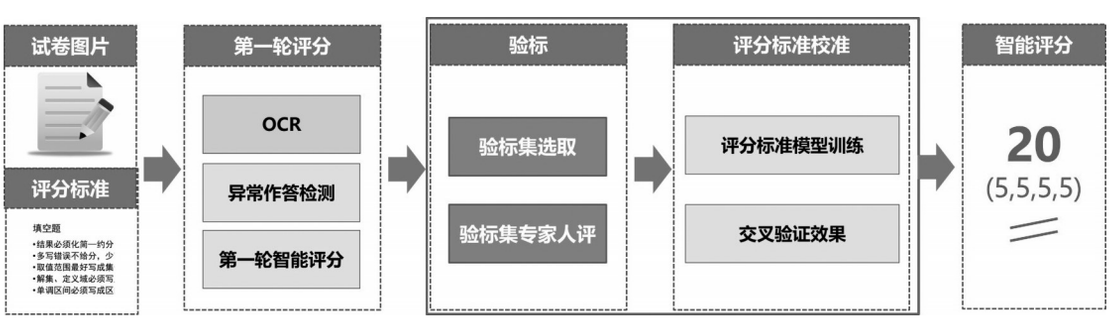


图1 数学填空题智能评分流程示意图

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

表1 2018年和2019年高考数学(文科、理科)全国Ⅰ卷填空题机评分与报道分一致率 %

题号	2018年文科数学	2018年理科数学	2019年文科数学	2019年理科数学
填空题(第13~16题)	99.89	99.91	99.61	99.42
第13题	99.98	99.98	99.76	99.86
第14题	99.98	99.96	99.94	99.79
第15题	99.97	99.99	99.96	99.82
第16题	99.96	99.99	99.95	99.94

强的,无论是人工评分还是计算机智能评分都不会出现大的误判;因此,当高置信度样本出现极少数人机不一致的情况时,往往都是因为对考生书写内容识别存在差异。

通过以上分析可以得出,在进行数学填空题的智能评分时,以同一考生人机评分一致率≥99%为标准,计算机可以在样本总量的55%~75%进行高置信度的智能评分,其评分结果能够达到与评卷教师完全一致的要求,从而可以替代人工参与到一评过程。人工智能评分能够完成多少评卷量,先决条件在于转写识别的精度,尤其在手写数字不规范的情况下,更容易造成识别错误。当人工智能技术对数学填空题识别转写能力得到进一步提升时,能够进行人工智能评分的样本量就会增加,参与一评的比例就会得到提高。

2 人工智能评分参与一评的总体设计

本研究的设计是,在原有人工双评模式下,选取部分样本进行智能评分,并作为一评分参与到整个评卷过程中。智能评分样本的选取原则是以对该样本评分准确性预判大于99%作为前提,数量上一般不低于待评样本总量的60%(另外40%需要人工二评完成)。当人一评和机一评出现不一致而超出差值阈限(数学填空题的差值阈限为0分)时,或人工一评和人工二评不一致而超出差值阈限时,系统自动进入人工三评或专家终评环节。人工智能评分参与一评的评卷模式见图2。

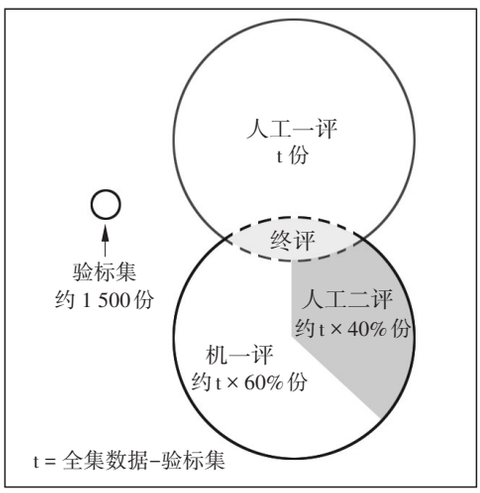


图2 人工智能评分参与一评的评卷模式

2.1 流程设计

流程设计采用最小化原则,即在已有平台和系统的基础上,做到硬件结构变动的最小化、软件功能变动的最小化及对评卷过程影响的最小化。本研究依托已有“评卷辅助平台”,在保证“网上评卷系统”与“智能评分系统”各自独立的前提下,通过增加或修改数据接口,实现各系统之间的访问和数据交互对接,重点解决验标集专家评分、验标集专家评分导入智能评分系统、高置信度智能评分结果导入网上评卷系统等问题。“评卷辅助平台”增加5个接口、修改1个接口,具体内容见表2。其中,修改后的“机评成绩上传”接口中,增加了上传成绩的细项分格式,适用于填空题每一小题的成绩上传,使用“|”进行分割,样式为“成绩1|成绩2|成绩…|成绩N”。例如,数学填空题有4个小题,某考生小题得分为5分、5分、0分、5分,则提交给“评卷辅助平台”的细项分为5|5|0|5。

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

表2 “评卷辅助平台”增加和修改的接口

序号	接口功能	接口名称	使用方	备注
1	验标集上传	uploadYbj	“智能评分系统”	新增
2	验标集评分下载	downloadYbjCj	“智能评分系统”	新增
3	机评成绩上传	uploadJpcj	“智能评分系统”	修改
4	验标集下载	downloadYbj	“网上评卷系统”中的验标集人评	新增
5	验标集评分上传	uploadYbjCj	“网上评卷系统”中的验标集人评	新增
6	机评成绩下载	downloadJpCj	“网上评卷系统”中的教师正评	新增

在技术层面上,将验标集的专家评分独立出来,等同于在网评系统中增加了一个新科目,软件直接使用网评系统的功能模块,硬件则保持独立部署,利用“评卷辅助平台”的控制功能,实现各系统之间的配合应用,其拓扑结构如图3所示。

智能评分参与一评要考虑到从正评开始到评卷结束的整个评卷期间,保持人评与机评在流程上的统一与时间上的衔接,设计工作流程如图4所示。图中黑框所标注部分(7月12—14日)为智能评分参与一评的重要时间段,具体内容参见3.1验证步骤。

2.2 关键环节的操作设计

2.2.1 验标集挑选策略

通过对全部样本数学填空题扫描图像的识别文本进行聚类分析,确定验标集,步骤如下:1)挑选基础集。根据每小题的聚类结果,选取聚类最多的小题,按每个种类的考生作答样本不低于2个的方式选取基础集。2)按小题逐个补充未覆盖到的种类,确保每个种类考生作答样本数量不低于2个,优先挑选那些能覆盖多个小题的样本,直到每小题均覆盖所有考生全部作答种类为止。

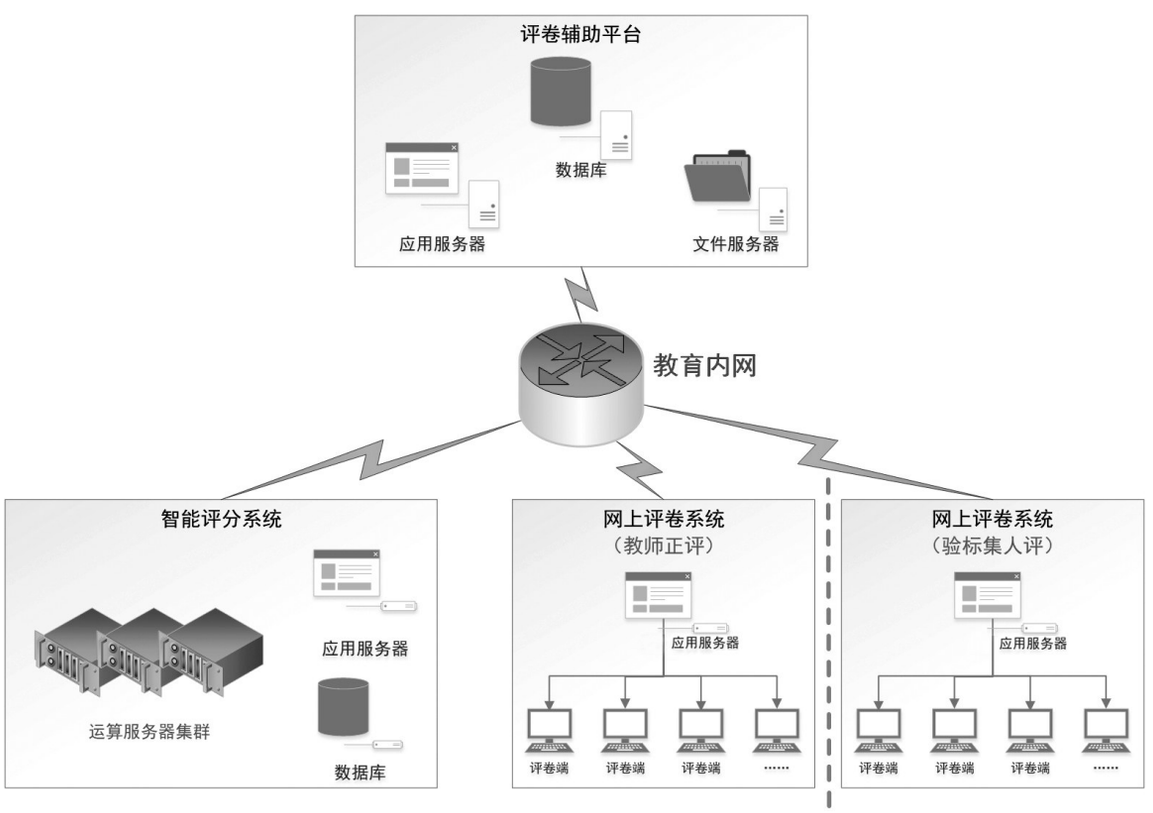


图3 人工智能评分参与一评的拓扑结构

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

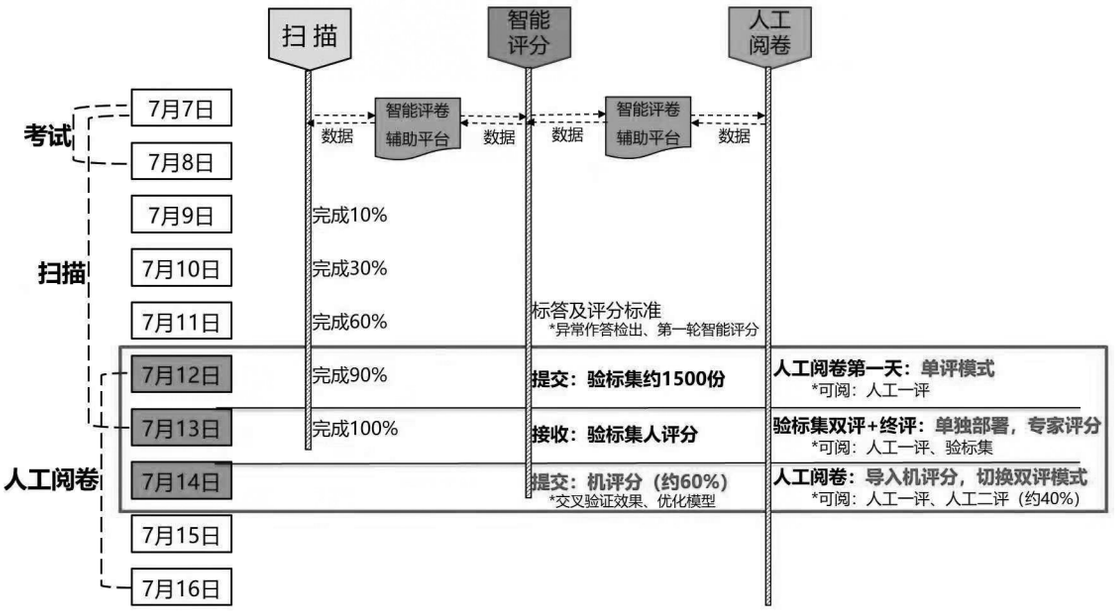


图4 人工智能评分参与一评的工作流程

根据实验数据，按照文理科各20万考生进行测算，验标集数量一般为1 000~1 500份。

2.2.2 验标集专家评分

组织专家对验标集进行评分，确保验标集的评分结果完全准确，以保证对评分模型的优化训练效果。就系统而言，对验标集进行专家评分需要单独处理，学科组需要通过“网上评卷系统”专门安排评卷专家针对验标集进行人工双评。评分过程结束后，“智能评分系统”可以通过数据接口获取到验标集的专家评分。

2.2.3 智能评分结果提交

通过对智能评分引擎进行基于验标集专家评分的深度学习和优化训练后，完成对所有待评样本的智能评分，并提交高置信度样本的机评分数。这里，高置信度样本的最终数量视扫描图像的识别精度、图像转文本的准确程度，以及填空题正确答案的复杂程度和考生作答离散程度等因素决定。“网上评卷系统”可以通过数据接口获取到人工智能评分参与一评的机评分数。

2.2.4 模式设置

在智能评分提交结果之前，“网上评卷系统”应将数学填空题设置为单评模式，评卷教师对全部考生进行“人一评”。在智能评分提交结果之后，“网上评卷系统”需要将数学填空题设置为双评模式，即如果采信“机一评”分数，“网上评卷系统”可将这些“机一评”分数设置为有效，并完成剩余的“人一评”“人二评”，以及质检、终评任务；如果不采信“机一评”分数，可以不对机评分数进行导入，直接继续原有人工双评流程，此时的智能评分结果可作为“计算机智能评分辅助网上评卷质量监控”功能模块，参与到整个网上评卷过程。

3 人工智能评分参与一评的应用性验证

在前述研究基础上，对2020年高考文科数学和理科数学填空题在评卷过程中同步进行人工智能评分参与一评的应用性验证。选取安徽省考生样本，其中文科数学填空题考生作答样本量为19.81万份，理科数学填空题考生作答样本量为22.7万份。

3.1 验证步骤

1）在人工正评开始第1天，在总量>90%已扫描数学填空题图片识别文本中，文科数学挑选出验标集1 092份，理科数学挑选出验标集1 129份。

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

2)人工正评第2天,组织专家通过网上评卷系统对验标集样本进行人工双评,计算机以验标集专家评分结果作为标准,训练并优化评分引擎,在扫描任务结束后,对全部样本进行计算机智能评分。

3)人工正评第3天,文科数学填空题提交高置信度机评结果13.23万份(占比66.78%),理科数学填空题提交高置信度机评结果14.81万份(占比65.24%)。“机一评”数据通过“评卷辅助平台”在线传输到网上评卷系统中。

4)智能评分系统提交高置信度样本的“机一评”分数后,在后台与网上评卷系统中的“人一评”评分逐一进行比对,文科数学填空题完全一致率为99.59%,理科数学填空题完全一致率为99.50%,符合预期目标,并达到应用水平。至此,从结构设计、程序开发、软硬件环境调整,到主要流程实现,智能评分参与一评过程的主要环节均已顺利实现。

3.2 数据分析

在高考网评工作结束之后,对高置信度样本的全部数据按小题一致率进行后期分析,对“机一评”分数与实际全部采用人工双评模式评分进行比对,“机一评”分数与人评报道分一致率均超过99.90%,见表3。

表3 2020年高考数学(文科、理科)填空题“机一评”与人评报道分一致率 %

题号	一致率
2020文科数学第13题	99.97
2020文科数学第14题	99.92
2020文科数学第15题	99.91
2020文科数学第16题	99.97
2020理科数学第13题	99.95
2020理科数学第14题	99.96
2020理科数学第15题	99.97
2020理科数学第16题	99.98

由表3可见,对于数学填空题采用聚类分析后,人工智能评分具有极高的准确性,这种智能评分参与一评的“人机协作”模式,既能够有效节省评卷教师的评卷工作量,又能够发挥计算机智能评分的高稳定性优势,从而提升评卷的质量与效率。

4 结束语

“人机协作”评卷模式流程组织方案的技术特点可以总结归纳为3个方面:一是高融合性。将智能评分参与一评独立部署,通过增加数据接口,扩充“评卷辅助平台”应用功能,保持与网上评卷系统之间的密切联系。在网上评卷系统中增加验标集专家评分功能模块,使智能评分参与一评成为替代一评的标准流程,既保证人工正式评卷流程的顺畅,又确保各系统独立运行和相互之间的数据安全性。二是高可用性。“网上评卷系统”支持随时在“人一评”+“机一评”+“人二评”模式和“人工双评”模式之间的切换,智能评分系统支持在“机一评”模式和“智能评分辅助网评质量监控”模式之间的切换,能够切实降低智能评分参与一评的风险,确保评卷进度和评卷质量。三是可追溯性。单独部署的“验标集专家评分系统”、用于人工评卷的“网上评卷系统”和“智能评分系统”3个系统之间数据独立运行、独立存储,通过“评卷辅助平台”进行数据交换,完成在线实时对接,并形成操作日志,关键节点均可实现可追溯、可审计、可恢复的设计目标。

智能评分参与一评在实践中需要注意以下2个方面的问题:第一,通过聚类分析法挑选出的验标集要涵盖考生的所有答案,以最大限度地减少错判误判。学科组在制定填空题的评分细则时,要允许正确答案有不同的表达形式。在对考生的答题信息进行分析时,要将出现的各种作答信息全部挑选出来,形成足够数量的验标集,以最大限度地保证智能评分结果的准确性。第二,对所有细节问题必须考虑充分,才能满足实战条

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

件和实用要求。从应用结果来看，各系统增加的数据接口准确，软硬件部署和时间安排符合网评工作实际要求，尤其在时间节点的安排上，完全与网评实施过程相吻合，评卷教师的评卷工作节奏与往年保持一致，除学科专家组外，评卷教师对智能评分参与一评过程无感，能够做到无缝对接。在智能评分过程中，需要组织学科专家、质检组长、行业专家、管理人员和技术服务商共同组成评估专家组，将智能评分结果与人工评分结果逐一进行比对，对不一致的进行严格核查，准确判断对错问题及数量多少，审慎评估智能评分参与一评的可行性及风险程度。一旦人机结合的评分结果未能达到预期设计的标准和要求，决策者可随时按下暂停键，快速切换为原有方式，确保整个评卷按时完成，确保进度安排和质量要求。

高考填空题型通常是相对客观、可穷举答案的题型，随着算法的优化和技术难点的突破，完全可以借助人工智能的方法实现智能评分参与一评的设计目标，其评分准确性也会更加客观地得到验证，避免了人工智能评分的可解释性问题，使得计算机替代“人一评”成为可能。

参考文献：

[1] 何屹松，孙媛媛，汪张龙，等. 人工智能评测技术在大规模中英文作文阅卷中的应用探索[J]. 中国考试，2018(6)：63-71.

[2] 何屹松，徐飞，刘惠，等. 新一代智能网上评卷系统的技术实现及在高考网评中的应用实例分析[J]. 中国考试，2019(1)：57-65.

[3] 何屹松，孙媛媛，张凯，等. 计算机智能辅助评分系统定标集选取和优化方法研究[J]. 中国考试，2020(1)：30-36.

Application of Artificial Intelligence Scoring in the First-Round of the College Entrance Examination Online Scoring

HE Yisong[1], SUN Yuanyuan[1], JIANG Guangxian[2], ZHANG Kai[2]

(1. Anhui Education Examinations Authority, Hefei 230001, China;
2. IFLYTEK Co., Ltd., Hefei 230001, China)

Abstract: This study explores the feasibility of artificial intelligence scoring in the first-round of the college entrance examination scoring. On the basis of the original “Auxiliary Platform for Marking” application, a data exchange interface and expert scoring of the test-standard set are added, the study offers a relatively comprehensive process design from the two perspectives of management and application. The design scheme was applied in the mathematics blank filling items of 2020 college entrance examination. The results show that: the consistency rate of the total score of “machine scoring” and “human scoring” reached 99.50%, and the consistency rate between the scores of the “machine scoring” and the actual reports using the manual double scoring mode exceeds 99.90%. The application verification of artificial intelligence scoring shows that it is feasible to use computer instead of “human scoring” in the semi-objective blank filling items, and the new mode of “man-machine cooperation” has broad application prospects.

Keywords: artificial intelligence scoring; online scoring; manual scoring; online scoring of college entrance examination; man-machine cooperation scoring mode

（责任编辑：周黎明）

(C)1994-2021 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net