人机协同评分质量控制方法*

王 伟 赵英华
(教育部教育考试院,北京 100084)

提 要:全国大学英语四、六级口语考试是测试大学生英语口头交际能力的重要形式。传统的人工评分存在选聘评分员难、评分标准把握难、评分质量监控难等问题。基于人工智能的口语评分系统已在英语口语考试中广泛应用。本研究基于多次 CET-SET 模拟考试智能评分技术实验数据,探讨智能评分技术与人工评分相结合的人机协同评分质量控制方法的可行性。研究发现,不同定标方式下,计算机评分结果稳定、可靠;整卷评分方式下,计算机智能评分可作为一评或第三评质检;在不同任务维度上,对不同题型任务可灵活选择不同评分方式。本研究可以为 CET-SET 口语评分提供一个有效的解决方案,促进其规模化推广和应用。

关键词:四、六级口语考试;计算机智能评分;人机协同;定标;整卷评分;多任务评分
中图分类号:H319 **文献标识码**:A **文章编号**:1000 - 0100(2023)04 - 0097 - 8
DOI **编码**:10.16263/j.cnki.23 - 1071/h.2023.04.014

Approaches to Scoring Quality Control Through Human-machine Collaboration

Wang Wei Zhao Ying-hua
(National Education Examinations Authority, Beijing 100084, China)

The national College English Test (CET) spoken language test is an important exam that tests the oral communication abilities of college students. Traditional manual scoring has issues such as difficulty in selecting scoring personnel, difficulty in grasping scoring standards, and difficulty in monitoring scoring quality. Artificial intelligence-based spoken language intelligent scoring systems have been widely used in English speaking exams. Based on multiple CET-SET simulation exam intelligent scoring technology experiment data, this study explores the feasibility of a human-machine collaborative scoring quality control method combining intelligent scoring technology and manual scoring. The study found that under different calibration methods, computer scoring results are stable and reliable; under the whole paper scoring method, computer intelligent scoring can be used as a first or third-grade quality inspection; in different task dimensions, for different question types different scoring methods can be flexibly chosen. This study provides an effective solution for CET-SET oral language scoring, promoting its scale-up and application.

Key words: CET-SET; computer intelligent scoring; human-computer collaboration; standardization; holistic scoring; Multi-task scoring

1 引言

全国大学英语四、六级口语考试(CET Spoken English Test,简称 CET-SET),是用于测量我国大学生英语口头交际能力的一项重要考试。其考核形式多为开放性题目,旨在进一步提高在校大学生的英语口语水平。CET-SET 从 1999 年开始实施,早期以双考官面试方式进行,受考场数量、合格考官数量限制,每年口试规模最大控制在十万人次左右;自 2013 年改革为基于计算机的考试(Computer-based Test)后,考试规模进一步扩大,年考试规模超过百万人次(金艳等 2020:9)。该考试采用全国集中网上评分,评分教师需要仔细

* 本文系教育部教育考试院科研项目“人工智能技术在英语口语开放性试题评卷中的应用”(GK2019002)的阶段性成果。

作者电子邮箱:12557120@qq.com(王伟)

辨听考生所有作答语音后再进行评判，在工作强度和工作质量要求双高的情况下，出现选聘评分员难、评分标准把握难、评分质量监控难的“三难”情况，阻碍了该项考试的进一步推广（张晓艺 2019）。

基于人工智能的英语口语智能评分系统是指利用计算机智能口语评测系统自动对学习者的答题语音进行评价，包括发音错误检测、发音水平和口语表达能力评价。近些年，已在英语口语考试中广泛应用，如在北京、上海、广东等全国多个省市地区中高考英语听说考试中全面应用，累计服务考生量超过 4000 万（魏思等 2019：72 – 79，金艳等 2021：1 – 7）。因此，探索英语口语智能评分技术与人工评分相结合的人机协同评分质量控制方法，是突破现有“三难”问题的可行方案，是实现 CET-SET 考试大规模推广的有效途径。本文基于多次 CET-SET 模拟考试智能评分技术实验数据进行分析，论证智能评分技术与人工评分相结合的人机协同评分质量控制方法的可行性。

2　研究方法与过程

2.1 术语定义

为更好地理解本研究的相关内容，对设计核心概念术语进行定义如下：

（1）机器学习：是一门多领域知识交叉的应用型学科，涉及概率论、统计学、逼近论、凸分析、算法复杂度理论等多门学科。其专门研究如何设计和分析一些让计算机可以自动“学习”的算法，从数据中自动分析获得规律，并利用规律对未知数据进行预测。这些算法使得计算机获取模拟或实现人类的学习行为，以获取新知识或技能，重新组织已有知识结构使之不断改善自身的性能。

（2）计算机智能评分：是一种通过计算机在对作答内容进行全方位识别和内容分析关键特征提取的基础上，通过“学习”人工专家评分标准和所需预备知识，基于专家完成定标的样本集合构建评分模型，自动模拟人工专家对考生作答内容完成评分的技术。

（3）人机协同评分：是计算机智能评分参与到人工评分的过程中，分为两种方式：一种是计算机智能评分结果作为一评和人工一评评分结果再通过误差仲裁后计算出最终得分；另一种是计算机智能评分结果只是作为一项参考分参与到人工评分过程的质量监控中。

（4）评分标准：是文字版的评分实施细则，无论人工评分还是计算机智能评分均须按照此标准进行评分。在评分标准中，命题专家依据每个题型的考查目的，将考生的语言表现分解到多个考查维度进行评价，每个维度包含若干个评分点，并被划分成若干个得分等级（或档次），每个得分等级以文字形式描述对应的典型作答特征。例如，在短文朗读题型中，流畅是一个考查维度，对应的评分点有语速、不合理停顿、句子重音、意群停顿、语调、节奏，满分的典型作答特征可以描述为：语速自然，只在个别地方有不合理停顿；能正确处理句子重音、意群停顿；语调正确，节奏感强。

（5）定标集合：是由计算机进行特征分析和筛选，能够覆盖不同得分等级全部典型作答特征的考生答卷集合，由人工评分后，用于计算机学习掌握评分标准。

（6）整卷评分：是指计算机智能评分技术将考生一次考试试卷的所有语音作答结果综合评测，给出一个最终的结果。

（7）多维度评分：是指在人工评分或者计算机智能评分过程中，按照不同的特征维度给出分数，如语音语调、流利度、完整度等，通常这些维度与人工评分标准相互关联。

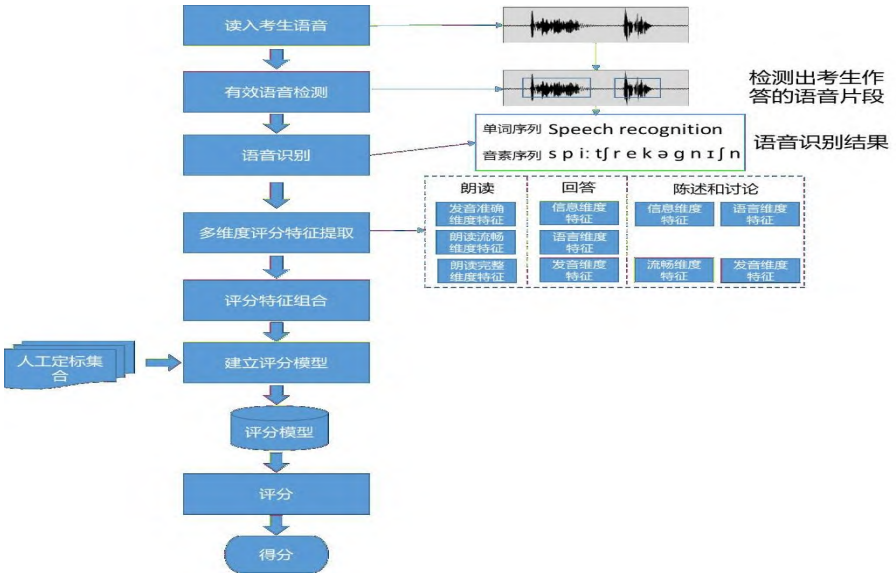
2.2 计算机智能评分技术原理

计算机智能评分技术原理的核心在于计算机能够从定标集合的人工评分结果中学习人工评分如何解读并执行评分标准，找到每份试卷的语音特征、语义特征等与评分标准的对应关系，使得计算机智能评分系统具备与人工一样的评分尺度，最终掌握并执行当次考试的人工评分标准。在技术实现上，计算机智能评分系统依据题型考查目的，将考生的语言表现拆解成相互独立的考查维度，每个维度对应一个考查点，列举出每一个考查点下能够反映考生水平的所有评分点，基于这些评分点提取评分特征。再从定标集合的人工评分结果的学习过程中，强化人工评分侧重度高的评分点，弱化人工评分侧重度低及不关注的评分点，实现当次考试人工评分标准的学习和掌握。计算机智能评分技术主要由考生语音数据处理、多维度评分特征提取、建立评分模型和回归评分 4 个部分构成，如图$_1$所示。

（1）语音数据处理：在语音数据处理阶段，将考生作答语音输入到系统中，由系统进行考生语音的处理，包括考生作答语音片段的提取、通过语音识别技术进行作答内容的识别提取，为多维度评分特征提取做基础信息的准备。此外，该阶段还会对无效语音进行提前筛除。

（2）多维度评分特征提取：为模拟贴近人工

评分过程，对于每一种题型，都会根据不同的维度和考查点从考生作答数据中提取相应的评分特征，最终形成多维度特征组合特征。如图$_1$所示，例如朗读题型会从发音准确度、朗读流畅度、朗读完整性等多个维度进行评价，问答题型会从信息、语言、发音多个维度进行评价。



图$_1$　计算机智能评分技术原理图

（3）建立评分模型：提取出定标集合考生的评分特征后，对于每一个题型，计算机以人工分为目标，通过算法学习评分特征与人工分之间的映射关系（即回归模型），拟合出人工评分的综合给分模式，从而学习掌握评分标准。其中最简单的映射关系是评分特征加权，即每一个评分特征被赋予一个权重，相乘后累加。映射关系保存为计算机可以读取和执行的评分模型。为更准确地拟合人工分，一般采用多个独立的算法学习多个独立的映射关系，然后进行组合，相互补充，一般采用取平均分的方式进行组合。

（4）回归评分：评分模型建立后，就可以在提取全体考生的评分特征之后，使用评分模型对全体考生进行智能评分，获得考生每一题的得分。

2.3 计算机智能评分实验方案设计

2.31 验证整卷评分方案

通常计算机智能评分以单题评价为主，采用常规的机评流程：语音识别、音质异常样本检测、定标学习训练、全集智能评分。由于 CET-SET 以多题综合评价为主，因此设计出整卷智能评分流程，即以单题智能评分为基础，依据评分模型得到全集各个题目的总分，并进行低置信度数据筛除，从而达到整卷智能评分的效果，如图$_2$所示。



图$_2$　整卷智能评分流程

整卷评分方案又分为整卷定标方案和单题定标方案。整卷定标以人工定标整卷的方式对每个考生的完整作答有全貌了解后，给出基于每个题目的分数和总分，并训练评分模型完成对整卷的评分；单题定标则基于每个单题分别进行人工定标评分并训练单题评分模型出分，再进行累加以获得每个考生的总分。

2.32 验证分任务、多维度评分方案

将 CET-SET 四级调整后分为 A 朗读题、B 问答和陈述题、C 讨论题 3 个任务，每个任务按照不同维度进行侧重评分，并且按照一定计分权重进行计算，如表$_1$ 所示：

表$_1$　CET-SET 四级任务划分与多维度评分标准

四级	A 朗读题	B 问答和陈述题	C 讨论题
评分标准	整体评分：包含语音和语调；表达流利度；内容完整度。	B1 语言表达	C1 语言表达
		B2 语篇组织	C2 语篇篇幅（对交际任务贡献）
		B3 内容相关和丰富度	C3 交际策略和语用
计分规则	A＊0.8	B1＊0.4＋B2＊0.4＋B3＊0.8	C1＊0.4＋C2＊0.4＋C3＊0.8
计分说明	总分为 4 分	3 个标准均为 0－5 分；加权后总分为 8 分。	3 个标准均为 0－5 分；加权后总分为 8 分。

将 CET-SET 六级调整后分为 A 陈述题、B 讨论题、C 问答题 3 个任务，每个任务也按照不同维度进行侧重评分，并且按照一定计分权重进行计算，如表$_2$ 所示：

表$_2$　CET-SET 六级任务划分与多维度评分标准

六级	A 陈述题	B 讨论题	C 问答题
评分标准	A1 语言表达	B1 语言表达	C1 语言表达
	A2 语篇组织	B2 对交际任务贡献	C2 语篇组织
	A3 内容相关和丰富度	B3 交际策略和语用	C3 内容相关和丰富度
计分规则	A1＊0.4＋A2＊0.4＋A3＊0.4	B1＊0.2＋B2＊0.2＋B3＊0.8	C1＊0.2＋C2＊0.2＋ C3＊0.2
计分说明	3 个标准均为 0－5 分；加权后总分为 6 分。	3 个标准均为 0－5 分；加权后总分为 6 分。	3 个标准均为 0－5 分；加权后总分为 3 分。

基于该套模型，计算机智能评分按照任务进行人工定标和机器学习，最终分任务、分维度给出分数。

2.4 计算机智能评分验证的实验过程

从 2016 年开始，由科大讯飞智能评分技术团队配合进行 CET-SET 题型机评的效果实验，主要测试任务如下：

表$_3$　CET-SET 整卷机评研究任务过程表

实验任务	测试内容	目的
测试任务 1	单题定标和整卷定标两种方式，均采用 500 份定标集分别进行机器智能评分。	验证效果最优的人工定标模式；验证计算机智能评分辅助人工评分的可行性及当前阶段的最优应用模式；形成计算机辅助人工评分的智能评分方案。
测试任务 2	根据分任务、分维度理论方案设计，选取四级、六级数据，分别按照任务、维度学习评分，最终按照计分规则计算出分。	研究在新的任务分维度评分方案的理论设计下，计算机智能评分的效果。

表4　CET-SET 整卷机评验证性研究任务数据使用情况表

任务	定标方式	试卷题型	样本总量	定标量	验证量	数据来源
测试任务 1	整卷定标	四级 F1△、F2△	48892	500	43357	△：2018 年 11 月考试数据 *：2019 年 11 月考试数据
		六级 S1△、S2△	37003	500	34174	
		四级 F1*、F7*	36288	500	33124	
	单题定标	四级 F1、F2	48892	500	43357	
		六级 S1、S2	37003	500	34174	
		六级 S4	22383	600	200	
测试任务 2	分任务定标	四级 A 朗读题	12618	500	400	2020 年 11 月考试数据
		四级 B 问答和陈述题	12618	500	400	
		四级 C 问答题	12618	500	400	
		六级 A 陈述题	22196	900	700	
		六级 B 讨论题	22196	500	400	
		六级 C 问答题	22196	500	400	

如表3、表4所示，多次测试实验的主要内容和目标为：(1)通过计算机智能评分技术在不同人工定标方式下的人机评分一致率效果，验证其稳定性和可靠性；(2)探索在不同机评分方式下、不同题型场景中，人机协同的质量控制方法。

3　研究成果

3.1 不同定标方式下，机评效果的稳定性与可靠性分析

测试任务 1 中，首先基于四级和六级数据样本集合，对比单题定标和整卷定标的机评效果。如表5 所示，两种定标方式下，机器评分各项关键指标差异较小，具备相当的稳定性。考虑到整卷定标的人工评分效率高于单题定标，因此建议采用前者。

表5　测试任务 1：CET-SET 四、六级验证全集上两种定标方式智能评分效果对比

	四级验证样本集合		六级验证样本集合	
	单题定标	整卷定标	单题定标	整卷定标
人机评分相关度	0.76	0.78	0.72	0.72
分差≤1.5 分占比	87.84%	88.92%	95.69%	95.62%
分差≤3 分占比	99.52%	99.73%	99.94%	99.96%

基于 2019 年四级两套试卷样本，在整卷定标方式下，对比人工评分和机器评分的效果。如表6 所示，以报道分为参考基准，人 1 评、人 2 评、机评分与报道分的相关度基本相当、关键指标同档一致率分别为：64.54%、64.60%、75.23%，计算机评分明显高于人工两个评次。因此，整卷定标方式下，计算机智能评分体现出与报道分更好的一致性，显著优于人工单评次。

表6　测试任务 1：计算机评分与人工两评次间的效果对比

类型	人 1 评－人 2 评	人 1 评－报道分	人 2 评－报道分	机评分－报道分
人机评分相关度	0.63	0.86	0.85	0.83
与报道分评分同档次样本占比	–	64.54%	64.6%	75.23%
分差≤1.5 分占比	84.86%	97.36%	97.24%	95.98%
分差≤3 分占比	99.34%	99.93%	99.88%	99.92%

如表7 所示，在测试任务 2 中使用分任务、分维度评分方式，机评分与报道分的相关度、一致率等关键指标上，在四、六级总共 6 个任务上都表现出较好的效果。这可以证明：在分任务、分维度评分模式下，计算机智能评分结果与最终报道分的效果高度一致，达到人工相当水平。

表7　测试任务 2：计算机评分与人工两评次间的效果对比

	关键指标	机评分－人 1 评	机评分－人 2 评	机评分－报道分	人 1 评－人 2 评
四级 A	相关度	0.697	0.686	0.763	0.618
朗读题	一致率(分差≤0.8)	99.00%	97.25%	100.00%	97.00%
四级 B	相关度	0.704	0.760	0.772	0.674
问答和陈述题	一致率(分差≤1.5)	84.50%	91.00%	92.50%	78.25%
四级 C	相关度	0.731	0.769	0.785	0.741
讨论题	一致率(分差≤1.5)	88.50%	86.75%	93.00%	81.00%
六级 A	相关度	0.723	0.693	0.779	0.649
陈述题	一致率(分差≤1.0)	89.71%	88.14%	95.14%	79.14%
六级 B	相关度	0.572	0.614	0.676	0.575
讨论题	一致率(分差≤1.0)	83.50%	88.25%	92.75%	79.75%
六级 C	相关度	0.739	0.710	0.797	0.643
问答题	一致率(分差≤0.6)	93.75%	95.75%	97.25%	91.75%

3.2 不同机评分方式下、不同题型场景中，人机协同的质量控制方法探索

3.21 整卷评分方式下，人机协同的质量控制方法探索

基于前面实验结论，在整卷评分方式下，计算机智能评分结果比人工单评次具有与最终分更高的一致性，因此可以使用计算机智能评分结果辅助评分过程质量控制或代替人工一评。表8中，在测试任务 1 验证集合上，在需要仲裁评分的数据集合上以仲裁分为基准做机评分与仲裁分的差异分析：机评分与仲裁分的人机相关度、同档一致率都明显高于人 1 评、人 2 评，人工两评仲裁数据集合上机评介入会较大提升评分质量。因此，在整卷评分方式下，计算机智能评分代替人工一评或作为第三评辅助质量检查具有可行性。

表8　测试任务 1：人人仲裁数据上效果分析

类型	测试任务 1：四级验证集合			测试任务 2：四级验证集合		
	人 1 评－仲裁分	人 2 评－仲裁分	机评分－仲裁分	人 1 评－仲裁分	人 2 评－仲裁分	机评分－仲裁分
人机相关度	0.39	0.33	0.70	0.37	0.29	0.76
同档一致率	28.59%	26.90%	40.76%	16.42%	12.02%	75.07%
邻档一致率	64.36%	62.17%	89.58%	73.90%	70.38%	98.24%

3.22 分任务、多维度评分方式下，人机协同的质量控制方法探索

通过模拟代入机评结果到实际应用场景中分析，人评终分用作一个评次，将机评分用作另一评次、超出仲裁分差阈值部分样本由专家进行仲裁、未超出仲裁分差阈值部分按照双评规则取平均分，以该分数作为基准分进行效果分析。如表9所示，在四级 A 朗读题、四级 B 问答和陈述题、六级 A 陈述题、六级 C 问答题等各题型上，机评分－基准分的相关度均在 0.91 以上，一致率均在98.43% 以上，机评分结果可信，直接采用或作为一评使用具有可行性。

表9　测试任务 2：四级 A、四级 B、六级 A、六级 C 各任务题型和基准分对比

题型	机评分－基准分		人评终分－基准分	
	相关度	一致率	相关度	一致率
四级 A 朗读题	0.919	100.00%	0.956	100.00%
四级 B 问答和陈述题	0.937	99.25%	0.911	96.75%
六级 A 陈述题	0.916	98.43%	0.950	99.29%
六级 C 问答题	0.931	100.00%	0.954	99.50%

再进一步分析四、六级讨论题任务的效果，如表10所示，用同样方式取基准分，比较人 1 评、人 2 评、机评分的评分有效率，这个指标是指相关评次的分数可以被用于生成考生最后成绩的组成部

分，而不因为分差等原因被舍弃，机评分有效率平均高出 4.25 个百分点。且如表$_{11}$所示，若进行机评分代替人工一评分场景模拟测试，机评分和人 1 评、机评分和人 2 评质检的一致率均高于人 1 评和人 2 评。由此可知，在该评分方案下，四级 C 和六级 B 讨论题任务若采用机评分代替人工一评既可以保障质量，也可以降低仲裁数据量。

表$_{10}$　测试任务 2：四级 C、六级 B 各任务题型和基准分对比

题型	机评分评分有效率	人 1 评评分有效率	人 2 评评分有效率
四级 C 讨论题	98.50%	95.50%	96.00%
六级 B 讨论题	99.25%	93.25%	93.75%

表$_{11}$　测试任务 2：四级 C、六级 B 各任务题型和基准分对比

题型	人 1 评 - 人 2 评		机评分 - 人 1 评		机评分 - 人 2 评	
	相关度	一致率	相关度	一致率	相关度	一致率
四级 C 讨论题	0.741	81.00%	0.731	88.50%	0.769	86.75%
六级 B 讨论题	0.575	79.75%	0.572	83.50%	0.614	88.25%

3.23 机器辅助人工评分改善评分质量的定性分析

进一步在上述 2 种应用模式下，定性分析机器评分替代人工一评如何改善评分质量。评分质量改善的样本主要包括 2 类：(1) 中高水平作答样本(人工评分偏低，可能是人工评分不稳定导致)；(2) 音量小、噪声大、失真等录音质量不佳样本(人工评分偏低，可能是录音质量差增加人工听辨难度)。另外，机器对于离题和背稿样本评分存在偏高问题，但由于采用人机互评模式，该类数据会进入仲裁流程，不影响最终评分质量。

4　总结与展望

4.1 总结

“选聘评分员难、评分标准把握难、评分质量监控难”是全国大学英语四、六级口语考试大规模开展的主要难题。随着计算机智能评分系统在国家普通话水平测试、中高考英语听说考试等测试中的全面开展和应用，该系统已经达到可用水平，是解决这些问题的一个重要研究方向。本研究结合多轮测试任务，针对实际测试数据对比人工评分和计算机智能评分的效果，以此来论证计算机智能评分技术是否可以达到应用水平，主要研究结论如下：

首先，不同定标方式下，机评效果具有稳定性和可靠性。根据实验结果分析，在单题定标、整卷定标、分任务、分维度定标评分几种人工定标评分方式下，计算机评分结果与人工最终分都能取得较好的一致性，进而证明计算机智能评分是可靠的，并且不受定标评分方式影响，具有稳定性。同时，结果显示，在多个测试任务上，机评分与基准分的一致率都明显高于人工单评与基准分的一致率，说明机评分效果优于人工一评评分水平，效果可靠。基于该结论，在实际应用场景中，可基于考试评价的需要，灵活选择人工定标方式。

其次，整卷评分方式下，将计算机智能评分作为一评或第三评质检具有可行性。计算机智能评分结果能用作一评或者第三评质检的基本条件是计算机智能评分具有较好的评分准确性。从实验结果数据看，计算机智能评分均表现出与基准分更一致的结果，并且明显高于人工单评次结果，因此，计算机智能评分结果可以作为一评或者第三方质检使用。

再次，分任务、分维度评分方式下，朗读、问题、陈述等题型任务直接采用计算机智能评分，讨论题将计算机智能评分作为一评具有可行性。从朗读、问题、陈述等题型任务的计算机智能评分与基准分的一致率可知，计算机智能评分在这几个题型任务上表现出与基准分高度一致的结果，与人工评分结果相当，因此若直接采用计算机智能评分和当前采用人工评分结果相当。在讨论题型任务上，一致率略低，但机评分的有效率较高，作为一评分使用能够达到与人工两评相当的效果，且降低仲裁量、提升评分效率。该结论说明在分任务、分维度评分方式下，可以基于题型的特点选择应用方式，同时也表明计算机智能评分技术在不同题型上，可基于实际应用场景灵活选用。

4.2 展望

基于该研究结论,将计算机智能评分技术应用于全国大学英语四、六级口语考试中具备一定可行性。但将该技术应用于实际考试评分场景中,需要进一步确定应用方式、人机协同的评分模式和流程、评分质量保障体系的修改等。这里从实验结果出发,对未来应用展望如下。

首先,结合已有研究成果,确定采用的人工定标方式和应用方式。进一步分析和研究计算机智能评分技术加入后,目标采用的定标方式和评分方式。此外,确定定标和评分方式后,须要结合题型的计算机智能评分效果和优缺点,进一步确定应用方式,如朗读题型可采用计算机智能评分、讨论题型采用"1 人 +1 机"评分模式等。

其次,在正式考试评分过程中,增加计算机智能评分流程,进行人机协同模式的试点和验证。定标和评分应用方式确定后,须要进行人工评分和计算机智能评分工作流程的匹配,输出标准化流程方案,包含但不限于工作流程、人工定标集合抽取方案、计算机智能评分作为一评的使用方案、计算机智能评分作为第三评辅助质检方案等。同时,需要进一步在实际考试中以真实场景仿真的方式进行实际流程的演练和磨合。

再次,进一步优化评分质量保障体系。为保障评分质量,从 3 个方面建立起严谨的质量保障体系。

第一,完善的人工评分质量保障机制。通过对评分员建立培训、试评和考核环节,保证所有评分员理解评分标准,掌握同样的宽严尺度,从而保证评分员在正式评分任务中的评分质量。在培训环节,评分组长依据标杆数据,向评分员讲解评分标准;在试评环节,随机抽取一定量考生答卷,所有评分员同时进行评分,评分组长可以查看本组全部评分员对同一份试卷的打分情况,对评分结果不一致情况进行原因分析,从而改进评分员的评分质量。通过以上机制,确保人工定标和全部考试正式人工评分的准确性,从而保证计算机学习后评分以及最终人机协作评分的准确性。

第二,完善的异常数据筛选机制。从录音质量、考生语音清晰度、考生作答内容 3 个层面,将录音质量低、发音不清晰、包含题目无关作答、离题等计算机无法准确评分的数据筛选出来,采用全人工评分的方式,保证这类数据评分的准确性。

第三,严谨的人机协同评分结果融合机制。对于非异常数据,通过慎重评分、设置三评仲裁等一系列方式,建立起严谨的人机评分结果融合机制,最大程度降低考生最终成绩的误差,以保证评分质量。对于每一题,计算机智能评分结果作为一个评次,人工评分结果作为另一个评次,最终成绩的计算过程如下:

当一评与二评中任意一个评次分数为 0 时,直接进入组长评分;

当一评和二评分差在阈值范围内,取平均分;

当一评与二评分差超出阈值范围,则采取三评,即增加人工第三评,分别与一评和二评计算两两分差,如果都不在阈值范围内,直接进入组长评分;如果都在阈值范围内,当两两分差相同,则取较高的两评分均值作为最终得分,否则取差值小的两评分均值作为最终得分;如果只有其中一组两评分在阈值范围内,则取该两评分均值作为最终得分。

参考文献

金 艳　王 伟　杨浩然. 语言测试中的技术应用:基于大学英语四、六级考试的实践分析[J]. 外语测试与教学, 2021(1). ‖ Jin, Y., Wang, W., Yang, H.-R. The Application of Technology in Language Testing: A Practical Analysis Based on College English Test Band 4 and Band 6[J]. *Foreign Language Testing and Teaching*, 2021(1).

金 艳　王 伟　张晓艺. 大学英语四级口语考试自动评分效度初探[J]. 中国考试, 2020(7). ‖ Jin, Y., Wang, W., Zhang, X.-Y. A Preliminary Study on the Validity of Automatic Scoring for College English Test Spoken English Test(CET-SET)[J]. *China Examination*, 2020(7).

魏 思　吴 奎　竺 博. 语音评测技术助力英语口语教学与评价[J]. 人工智能, 2019(3). ‖ Wei, S., Wu, K., Zhu, B. Speech Evaluation Technology Assists English Speaking Teaching and Evaluation[J]. *Artificial Intelligence*, 2019(3).

张晓艺. 大学英语口语考试构念效度研究:聚焦评分量表的开发与使用[D]. 上海交通大学博士学位论文, 2019. ‖ Zhang, X.-Y. An Investigation of the Construct Validity of the CET-SET: Perspectives on the Construction and Use of Rating Scales[D]. Shanghai Jiao Tong University, 2019.

定稿日期:2023 - 06 - 18　　【责任编辑　陈庆斌】